



Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica

ME607A - Séries Temporais

Aluísio de Souza Pinheiro

Análise de Série Temporal do Preço do Carvão de Algodão em Mato Grosso

Thales de Souza Crivillari

RA: 236312

Projeto P2

10 de junho de 2026

Resumo

Este trabalho realiza a análise completa da série do preço médio mensal de comercialização do caroço de algodão em Mato Grosso (fonte: IMEA/MT; jan/2023–abr/2026; $n = 40$ observações). Procede-se à análise descritiva e exploratória, ao teste de estacionariedade, à identificação e estimação de um modelo SARIMA, ao diagnóstico de resíduos e à previsão. Justifica-se a escolha do SARIMA frente às alternativas do conteúdo programático (suavização exponencial e ARIMA não-sazonal) pela presença de componente sazonal anual e tendência estocástica. Realiza-se um exercício de previsão treinando o modelo com as 30 primeiras observações e prevendo as 10 seguintes, com avaliação do resíduo de previsão. Como complementos críticos, discutem-se um modelo híbrido que acopla o SARIMA a um modelo bayesiano de coeficientes variáveis no tempo (objeto teórico do Projeto 1) e um modelo hierárquico que quantifica a diferença de preço entre safras, justificando a construção da série. Conclui-se que o SARIMA é adequado para previsão de curto prazo em condições regulares, mas perde acurácia diante de mudanças abruptas de patamar, como evidenciado no exercício de previsão.

1 Introdução e Motivação

O caroço de algodão é coproduto do beneficiamento da pluma: cada tonelada de algodão em caroço processada gera cerca de 60% de caroço. Sua oferta acompanha, portanto, o calendário de colheita e descaroçamento. A produção nacional concentra-se em Mato Grosso (cerca de 66%, segundo a Conab), o que torna o preço sensível ao ciclo da *safrinha*, com plantio após a soja e colheita entre julho e setembro. A proposta deste trabalho é justamente modelar a dinâmica dessa série e ver o quão bem conseguimos prevê-la. A Figura 1 apresenta a série.




Figura 1: Preço médio mensal do caroço de algodão em Mato Grosso (R\$/tonelada).

2 Dados e Pré-processamento

Trabalhamos com o indicador de preço médio mensal de comercialização do caroço de algodão do IMEA/MT.¹ Nos 21 meses de transição de safra, o indicador reporta simultaneamente o preço da safra anterior e da nova; nesses meses adotou-se a média aritmética das duas safras como preço mensal representativo, resultando em $n = 40$ observações. A média da série é R\$831/ton (desvio-padrão R\$207), com mínimo de R\$513 (jul/2024) e máximo de R\$1.269 (mai/2025). A Tabela 1 organiza os dados por ano e mês.

Tabela 1: Preço médio mensal por ano (R\$/tonelada), Mato Grosso. Fonte: IMEA.

Ano	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Méd.
2023	1026	1022	1020	990	927	909	835	717	663	576	602	618	825
2024	631	602	624	582	563	584	513	535	575	620	737	829	616
2025	946	974	1071	1174	1269	1216	1185	894	907	929	910	898	1031
2026	908	874	884	889	—	—	—	—	—	—	—	—	889

3 Análise Exploratória

Antes de escolher qualquer modelo, vale decompor a série para enxergar o que ela tem dentro. Aplicamos a decomposição clássica aditiva (Morettin; Toloi, 2018), que separa a série em $Z_t = T_t + S_t + a_t$: a tendência T_t é estimada por uma média móvel centrada

¹Os dados são disponibilizados pelo IMEA mediante solicitação no site da instituição, com envio do arquivo por *e-mail*. Para facilitar a reprodução, o banco foi espelhado em repositório público no GitHub.

de doze meses, que cancela a sazonalidade e suaviza o ruído; a sazonalidade S_t é obtida pela média dos desvios de cada mês do ano; e o resto é o resíduo a_t . A Figura 2 mostra o resultado: há uma tendência predominante e um componente sazonal anual de magnitude moderada, comportamento típico de preços de *commodities*. É justamente essa combinação de tendência com sazonalidade que aponta para um modelo da classe SARIMA.




Figura 2: Decomposição clássica aditiva da série em tendência, sazonalidade e resíduo.

4 Estacionariedade e Identificação

Para verificar estacionariedade aplicaram-se os testes de Dickey–Fuller aumentado (ADF) e KPSS (Morettin; Toloi, 2018; Shumway; Stoffer, 2017). Em nível, o ADF não rejeita a hipótese de raiz unitária ($p = 0,21$); após a primeira diferença, o ADF rejeita fortemente ($p = 0,0009$) e o KPSS não rejeita estacionariedade. Conclui-se que a série é integrada de ordem um, $I(1)$, fixando $d = 1$. As funções de autocorrelação (FAC) e autocorrelação parcial (FACP) da Figura 3 orientam a escolha das ordens dos componentes autorregressivo e de médias móveis, conforme a metodologia de Box e Jenkins descrita em Morettin e Toloi (2018).




Figura 3: FAC e FACP da série em nível e em primeira diferença.

5 Escolha e Estimação do Modelo SARIMA

5.1 Por que SARIMA?

Vale explicar por que SARIMA, e não outro modelo. O conteúdo do curso oferece três classes principais para uma série como esta: suavização exponencial, ARIMA não-sazonal e SARIMA. A suavização exponencial simples não acomoda sazonalidade, e o ARIMA não-sazonal não captura o ciclo anual identificado na análise exploratória. O modelo **SARIMA**(p, d, q)(P, D, Q) $_s$, que incorpora operadores sazonais multiplicativos (Morettin; Toloi, 2018), é portanto a escolha natural: combina a diferenciação para a tendência estocástica ($d = 1$) com os termos sazonais de período $s = 12$ exigidos pela periodicidade anual.

5.2 Seleção e diagnóstico

A identificação das ordens seguiu a metodologia de Box e Jenkins (Morettin; Toloi, 2018): a FACP da série diferenciada sugere um termo autorregressivo ($p = 1$), a FAC não indica estrutura de médias móveis relevante ($q = 0$), e o decaimento no *lag* sazonal aponta um componente autorregressivo sazonal ($P = 1$). Para confirmar, comparou-se uma grade de candidatos pelos critérios de informação de Akaike (AIC), Bayesiano (BIC) e Akaike corrigido (AICc), este último preferível em amostras pequenas. A Tabela 2 reúne os modelos com a mesma ordem de diferenciação ($d = 1, D = 0$), condição necessária para que os critérios sejam comparáveis entre si.

Tabela 2: Seleção de modelos SARIMA candidatos ($d = 1$, $D = 0$, $s = 12$), ordenados por AICc.

Modelo $(p, d, q)(P, D, Q)$	AIC	BIC	AICc
(1, 1, 0)(1, 0, 0)	305,4	309,2	306,5
(1, 1, 1)(1, 0, 0)	306,8	311,9	308,7
(0, 1, 2)(0, 0, 0)	412,2	416,9	412,9
(2, 1, 0)(0, 0, 0)	423,0	427,8	423,7
(1, 1, 1)(0, 0, 0)	423,8	428,7	424,6
(0, 1, 1)(0, 0, 0)	424,8	428,0	425,2
(1, 1, 0)(0, 0, 0)	433,3	436,5	433,6
(0, 1, 0)(0, 0, 0)	436,6	438,2	436,7

O modelo **SARIMA**(1, 1, 0)(1, 0, 0)₁₂ apresenta o menor AICc (306,5) e também o menor BIC, vencendo com folga os demais. A inclusão do termo de médias móveis (modelo (1, 1, 1)(1, 0, 0)) não melhora o ajuste e ainda penaliza o critério, confirmando $q = 0$. A diferença expressiva para os modelos sem componente sazonal (AICc acima de 412) demonstra que o termo sazonal (1, 0, 0)₁₂ é essencial: ignorá-lo deteriora substancialmente o ajuste.

Uma ressalva metodológica importante. Modelos com diferenciação sazonal ($D = 1$) chegam a exibir AIC aparentemente muito menor, mas esse valor não é comparável aos da Tabela 2: com período $s = 12$ e apenas $n = 40$ observações, a diferenciação sazonal consome doze observações e a verossimilhança passa a ser calculada sobre uma série efetivamente mais curta, o que reduz artificialmente o critério. Ademais, com tão poucos ciclos anuais completos, estimar um componente sazonal diferenciado é arriscado e instrável. Por isso a seleção foi restrita a modelos com $D = 0$, preferindo-se a parcimônia recomendada por Morettin e Toloi (2018) para amostras reduzidas.

A Figura 4 apresenta o ajuste e o diagnóstico dos resíduos do modelo escolhido. O teste de Ljung–Box no *lag* 12 não rejeita a ausência de autocorrelação ($p = 0,999$), indicando resíduos compatíveis com ruído branco. A normalidade é rejeitada (Shapiro–Wilk $p < 0,001$), comportamento esperado em preços de *commodities* sujeitos a choques. As métricas de ajuste dentro da amostra são MAE = R\$76/ton, RMSE = R\$177/ton e MAPE = 8,8%.




Figura 4: Ajuste do SARIMA e diagnóstico dos resíduos (QQ-plot, FAC, histograma).

6 Exercício de Previsão: 30 Observações de Treino, 10 de Teste

Para colocar o modelo à prova, fizemos um teste simples: estimamos o SARIMA com as **30 primeiras observações** (jan/2023–jun/2025) e previram-se as **10 seguintes** (jul/2025–abr/2026). A Tabela 3 apresenta, para cada mês, o valor observado, o previsto e o resíduo de previsão (observado menos previsto), além do erro percentual.

Tabela 3: Previsão fora da amostra: treino com 30 obs., previsão de 10. Resíduo = observado – previsto.

Mês	Observado	Previsto	Resíduo	Erro (%)
Jul/2025	1185	1158	+27	+2,3
Ago/2025	894	1141	−246	−27,5
Set/2025	907	1137	−230	−25,4
Out/2025	929	1140	−211	−22,7
Nov/2025	910	1167	−257	−28,2
Dez/2025	898	1189	−291	−32,5
Jan/2026	908	1220	−312	−34,3
Fev/2026	874	1226	−353	−40,4
Mar/2026	884	1253	−369	−41,7
Abr/2026	889	1282	−393	−44,2
MAE = R\$269/ton RMSE = R\$287/ton MAPE				29,9%

Os resíduos de previsão contam uma história interessante. O primeiro mês (jul/2025) é previsto com erro pequeno (+2,3%), mas a partir de agosto o resíduo torna-se sistematicamente negativo e crescente em módulo: o modelo **superestima** o preço. A explicação

é que o período de treino encerra justamente no pico histórico (mai/2025, R\$1.269), de modo que o SARIMA projeta a manutenção desse patamar elevado, ao passo que o preço real recuou abruptamente para a faixa de R\$900. Trata-se de uma **mudança de patamar** que o modelo, treinado num regime de alta, não antecipa. A Figura 5 ilustra graficamente o exercício: nove das dez observações permanecem dentro do intervalo de confiança de 95%, graças ao alargamento natural da incerteza com o horizonte, mas a previsão pontual afasta-se sistematicamente do observado.




Figura 5: Previsão fora da amostra com treino de 30 e horizonte de 10 observações.

7 Modelos Complementares

7.1 Modelo híbrido SARIMA → BTVC

Como extensão do objeto teórico do Projeto 1, considerou-se um modelo *híbrido* que acopla o SARIMA a um modelo bayesiano de coeficientes variáveis no tempo (BTVC). A ideia é usar a previsão do SARIMA como um regressor cujo **peso varia ao longo do tempo**: o componente bayesiano aprende, via MCMC, quanta confiança depositar na previsão clássica em cada instante. Formalmente,

$$y_t = \mu_t + \beta_t \hat{y}_t^{\text{SARIMA}} + s_t + \varepsilon_t,$$

em que μ_t é um nível local, s_t uma sazonalidade adaptativa, $\hat{y}_t^{\text{SARIMA}}$ a previsão do SARIMA e β_t o **peso dinâmico** (com β_t seguindo um passeio aleatório). A motivação é a limitação observada na Seção 6: um peso que se ajusta poderia reduzir a dependência do SARIMA quando este passa a errar.

A Figura 6 mostra o ajuste e a trajetória estimada de β_t . O peso médio do SARIMA é baixo ($\bar{\beta} \approx 0,16$), indicando que o componente bayesiano se apoia sobretudo no próprio nível adaptativo. Para uma comparação justa com o SARIMA, repetiu-se o exercício de previsão da Seção 6: treino com as 30 primeiras observações e previsão das 10 seguintes. A Tabela 4 apresenta os resultados.

Tabela 4: Previsão fora da amostra do híbrido: treino com 30 obs., previsão de 10. Resíduo = observado – previsto.

Mês	Observado	Previsto	Resíduo	Erro (%)
Jul/2025	1185	1091	+94	+8,0
Ago/2025	894	1033	−139	−15,5
Set/2025	907	1021	−114	−12,5
Out/2025	929	1049	−120	−12,9
Nov/2025	910	1098	−188	−20,6
Dez/2025	898	1136	−238	−26,5
Jan/2026	908	1163	−255	−28,0
Fev/2026	874	1182	−309	−35,3
Mar/2026	884	1217	−332	−37,6
Abr/2026	889	1248	−359	−40,4
MAE = R\$215/ton		RMSE = R\$234/ton	MAPE	23,7%

Comparando com a Tabela 3, o híbrido obteve erro um pouco menor que o SARIMA puro no mesmo período (MAE de R\$215 contra R\$269; MAPE de 23,7% contra 29,9%). O componente de nível adaptativo reagiu de forma ligeiramente mais rápida à queda de patamar, reduzindo o viés de superestimação. Ainda assim, como ambos os modelos foram treinados no período de preços elevados, nenhum dos dois antecipou plenamente a reversão, e os resíduos permanecem expressivos.

Custo versus benefício. A melhora obtida pelo híbrido é modesta e não compensa, na prática, o aumento de complexidade. Enquanto o SARIMA é estimado por máxima verossimilhança em fração de segundo, o híbrido requer inferência por simulação estocástica (MCMC), com tempo de ajuste de ordens de magnitude superior, além de um número muito maior de parâmetros (níveis, pesos e coeficientes sazonais variáveis no tempo). Para a série em questão, esse custo adicional não se justifica: o ganho preditivo é pequeno e o modelo mais simples (SARIMA) é preferível pelo princípio da parcimônia (Morettin; Tolo, 2018). O híbrido permanece relevante apenas como referência conceitual e como opção para cenários de instabilidade mais acentuada, em que a adaptabilidade dos coeficientes traria benefício maior.




Figura 6: Previsão fora da amostra do modelo híbrido: treino com 30 observações e horizonte de 10, com intervalo de credibilidade de 95%.

7.2 Modelo hierárquico de safra

A construção da série por média das safras (Seção 2) merece exame crítico, pois é uma decisão de pré-processamento que afeta toda a análise subsequente. Nos meses de transição, o IMEA reporta simultaneamente o preço de duas safras (a que se encerra e a que se inicia), e a média aritmética funde esses dois valores em um único ponto. Essa operação é cômoda, mas **descarta informação**: se as safras operam em patamares de preço distintos, a média mistura realidades diferentes. Nos 21 meses de sobreposição, a diferença média entre as duas safras foi de R\$274/ton, magnitude comparável ao próprio desvio-padrão da série (R\$207/ton), o que já sinaliza que a simplificação não é inofensiva.

Para quantificar formalmente essa variabilidade, ajustou-se um **modelo hierárquico de efeitos aleatórios**, em que cada safra s é tratada como um grupo com seu próprio nível. A formulação com um nível latente que evolui no tempo enquadra-se na classe dos modelos de espaço de estados (Shumway; Stoffer, 2017; Morettin; Toloi, 2018), aqui estendida com um efeito aleatório de grupo:

$$y_{t,s} = \underbrace{\mu_t}_{\text{nível comum}} + \underbrace{\alpha_s}_{\text{efeito da safra}} + \varepsilon_t, \quad \alpha_s \sim \mathcal{N}(0, \sigma_{\text{safra}}^2).$$

Aqui μ_t é um nível temporal compartilhado por todas as safras, α_s é o desvio sistemático de cada safra em relação a esse nível, e σ_{safra} mede a **dispersão entre safras**. A estrutura hierárquica representa um meio-termo entre dois extremos: agregar tudo (a média, que ignora a safra) e modelar cada safra isoladamente (que desperdiçaria a informação comum e sofreria com amostras pequenas por grupo). Ao estimar α_s e μ_t conjuntamente, o modelo separa o efeito da safra do efeito do período em que ela ocorreu.

A Figura 7 apresenta os efeitos estimados. As safras diferem de forma marcante ($\sigma_{\text{safra}} = \text{R\$}207/\text{ton}$): a safra 24/25 situou-se cerca de R\$320/ton *abaixo* do nível comum, enquanto a 22/23 ficou R\$161/ton *acima* e a 23/24, R\$69/ton *acima*. Em termos práticos, isso significa que a safra 24/25 foi comercializada num patamar substancialmente mais barato, coerente com o vale de preços observado em 2024 na Tabela 1. A magnitude de σ_{safra} , próxima do desvio-padrão da série, confirma quantitativamente que **a diferença entre safras é uma fonte de variação de primeira ordem**, não um detalhe secundário.

Implicação para a análise. O modelo hierárquico não invalida o uso da média: para o objetivo de modelar a dinâmica temporal *agregada* do preço de mercado, que é a pergunta central deste trabalho, a média continua sendo uma escolha legítima e usual. O que o hierárquico fornece é a **quantificação do custo** dessa simplificação, tornando-a uma decisão consciente e documentável, em vez de uma omissão. Caso o objetivo fosse outro, por exemplo comparar a rentabilidade entre safras ou prever o preço de uma safra específica, a abordagem hierárquica passaria de complemento a modelo principal.




Figura 7: Modelo hierárquico de safra. Painel (a): observações de cada safra (pontos coloridos) e nível comum μ_t estimado pelo modelo (linha vermelha). Painel (b): efeito α_s de cada safra, isto é, seu desvio sistemático em relação ao nível comum.

8 Discussão Crítica e Conclusão

Recapitulando o percurso: a série é $I(1)$, com tendência predominante e sazonalidade anual moderada. O modelo SARIMA(1, 1, 0)(1, 0, 0)₁₂ ajusta-se bem dentro da amostra, com resíduos compatíveis com ruído branco, e é adequado para previsão de curto prazo em condições regulares.

O exercício de previsão 30/10 (Seção 6) expõe a principal limitação do modelo: treinado num período de preços elevados, não antecipou a queda abrupta subsequente, acumulando resíduos de previsão de até R\$393/ton (MAPE de 30%). Essa fragilidade diante de mudanças de patamar é inerente a modelos de coeficientes constantes e motiva os complementos: o modelo híbrido SARIMA $\rightarrow$ BTVC (que reduziu modestamente o erro de previsão, de MAPE 29,9% para 23,7%, graças ao nível adaptativo, mas sem reverter plenamente o viés) e o hierárquico (que justifica e quantifica o custo da construção da série por média de safras).

Limitações e melhorias. (i) O tamanho amostral ($n = 40$) é modesto para a estimação sazonal. (ii) A presença de possível quebra de nível sugere o uso de análise de intervenção (item do conteúdo programático) para tratar explicitamente a mudança de regime. (iii) Variáveis exógenas, como câmbio e preço da pluma, poderiam ser incorporadas via modelo ARMAX.

Referências

- MORETTIN, P. A. *Econometria Financeira: Um Curso em Séries Temporais Financeiras*. 3. ed. São Paulo: Blucher, 2017. ISBN 978-8521210320.
- MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais, Volume 1: Modelos Lineares Univariados*. 3. ed. São Paulo: Blucher, 2018. ISBN 978-8521213512.
- SHUMWAY, R. H.; STOFFER, D. S. *Time Series Analysis and Its Applications*. 4. ed. Nova Iorque: Springer, 2017. ISBN 978-3319524511.