



Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica

ME607A - Séries Temporais

Aluísio de Souza Pinheiro

Análise de Série Temporal do Preço do Carvão de Algodão em Mato Grosso

Thales de Souza Crivillari

RA: 236312

Projeto P2

10 de junho de 2026

Resumo

Este trabalho realiza a análise completa da série do preço médio mensal de comercialização do caroço de algodão em Mato Grosso (fonte: IMEA/MT; jan/2023–abr/2026; $n = 40$ observações). Procede-se à análise descritiva e exploratória, ao teste de estacionariedade, à identificação e estimação de um modelo SARIMA, ao diagnóstico de resíduos e à previsão. Justifica-se a escolha do SARIMA frente ao ARIMA não-sazonal pela presença de componente sazonal anual e tendência estocástica, com a melhora no critério de informação confirmando essa escolha. Realiza-se um exercício de previsão treinando o modelo com as 30 primeiras observações e prevendo as 10 seguintes, com avaliação do resíduo de previsão. Como complemento crítico, discute-se um modelo híbrido que acopla o SARIMA a um modelo bayesiano de coeficientes variáveis no tempo (objeto teórico do Projeto 1). A quebra de patamar é interpretada pela estrutura de safras, mostrando que a diferença de preço entre as safras sobrepostas explica em boa parte a mudança de nível. Conclui-se que o SARIMA é adequado para previsão de curto prazo em condições regulares, mas perde acurácia diante de mudanças abruptas de patamar, como evidenciado no exercício de previsão.

1 Introdução e Motivação

O caroço de algodão é coproduto do beneficiamento da pluma: cada tonelada de algodão em caroço processada gera cerca de 60% de caroço. Sua oferta acompanha, portanto, o calendário de colheita e descaroçamento. A produção nacional concentra-se em Mato Grosso (cerca de 66%, segundo a Conab), o que torna o preço sensível ao ciclo da *safrinha*, com plantio após a soja e colheita entre julho e setembro. A proposta deste trabalho é justamente modelar a dinâmica dessa série e ver o quão bem conseguimos prevê-la. A Figura 1 apresenta a série.




Figura 1: Preço médio mensal do caroço de algodão em Mato Grosso (R\$/tonelada).

2 Dados e Pré-processamento

Trabalhamos com o indicador de preço médio mensal de comercialização do caroço de algodão do IMEA/MT.¹ Nos 21 meses de transição de safra, o indicador reporta simultaneamente o preço da safra anterior e da nova; nesses meses adotou-se a média aritmética das duas safras como preço mensal representativo, resultando em $n = 40$ observações. A média da série é R\$831/ton (desvio-padrão R\$207), com mínimo de R\$513 (jul/2024) e máximo de R\$1.269 (mai/2025). A Tabela 1 organiza os dados por ano e mês.

Tabela 1: Preço médio mensal por ano (R\$/tonelada), Mato Grosso. Fonte: IMEA.

Ano	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez	Méd.
2023	1026	1022	1020	990	927	909	835	717	663	576	602	618	825
2024	631	602	624	582	563	584	513	535	575	620	737	829	616
2025	946	974	1071	1174	1269	1216	1185	894	907	929	910	898	1031
2026	908	874	884	889	—	—	—	—	—	—	—	—	889

3 Análise Exploratória

Antes de escolher qualquer modelo, vale decompor a série para enxergar o que ela tem dentro. Aplicamos a decomposição clássica aditiva (Morettin; Toloi, 2006), que separa a série em $Z_t = T_t + S_t + a_t$: a tendência T_t é estimada por uma média móvel centrada de doze

¹Os dados são disponibilizados pelo IMEA mediante solicitação no site da instituição, com envio do arquivo por *e-mail*. Para facilitar a reprodução, o banco foi espelhado em repositório público no GitHub.

meses, que cancela a sazonalidade e suaviza o ruído; a sazonalidade S_t é obtida pela média dos desvios de cada mês do ano; e o resto é o resíduo a_t . A Figura 2 mostra o resultado: há uma tendência predominante e um componente sazonal anual de magnitude moderada, comportamento típico de preços de *commodities*. Vale observar que essa tendência não é estável: a série cai ao longo de 2023, atinge um vale em meados de 2024, sobe com força até o pico de maio de 2025 e volta a recuar em seguida. Ou seja, a direção do movimento muda várias vezes, em vez de seguir uma reta crescente ou decrescente. Esse comportamento caracteriza uma *tendência estocástica*, que vagueia sem um rumo fixo de longo prazo, e não uma tendência determinística que pudesse ser descrita por uma função do tempo. É precisamente esse tipo de tendência que justifica a diferenciação ($d = 1$) em vez da inclusão de um termo determinístico, e que será confirmado pelo teste de raiz unitária na Seção 4. É justamente essa combinação de tendência com sazonalidade que aponta para um modelo da classe SARIMA.




Figura 2: Decomposição clássica aditiva da série em tendência, sazonalidade e resíduo.

4 Estacionariedade e Identificação

Para verificar estacionariedade aplicaram-se os testes de Dickey–Fuller aumentado (ADF) e KPSS (Morettin; Toloi, 2006; Shumway; Stoffer, 2017). Em nível, o ADF não rejeita a hipótese de raiz unitária ($p = 0,21$); após a primeira diferença, o ADF rejeita fortemente ($p = 0,0009$) e o KPSS não rejeita estacionariedade. Conclui-se que a série é integrada de ordem um, $I(1)$, fixando $d = 1$. As funções de autocorrelação (FAC) e autocorrelação parcial (FACP) da Figura 3 orientam a escolha das ordens dos componentes autorregressivo e de médias móveis, conforme a metodologia de Box e Jenkins descrita em Morettin e Toloi (2006).




Figura 3: FAC e FACP da série em nível e em primeira diferença.

5 Escolha e Estimação do Modelo SARIMA

5.1 Por que SARIMA?

A análise exploratória evidenciou dois componentes na série: uma tendência estocástica e um ciclo sazonal de período anual. Esse ciclo é mensurável: calculando o desvio médio de cada mês em relação à média geral, observa-se que os preços são sistematicamente mais altos no primeiro semestre (abril a maio em torno de +80/+90 R\$/ton) e mais baixos no período de colheita (agosto a outubro entre -115 e -123 R\$/ton), configurando uma amplitude sazonal de cerca de R\$212/ton ligada ao calendário da safra.

Um modelo ARIMA não-sazonal trata apenas a tendência, por meio da diferenciação e dos termos autorregressivos e de médias móveis, mas **não possui mecanismo para a dependência entre observações separadas por doze meses**: por construção, seus operadores atuam apenas sobre defasagens de curto prazo (B , B^2 , ...), nunca sobre B^{12} . Assim, ele é incapaz de representar o ciclo anual identificado acima. O modelo SARIMA(p, d, q)(P, D, Q) $_s$ acrescenta operadores sazonais multiplicativos (Morettin; Toloi, 2006) que atuam justamente no período $s = 12$, modelando a relação entre cada mês e o mesmo mês do ano anterior.

A consequência dessa limitação do ARIMA não-sazonal é direta no ajuste: ajustando um ARIMA(1, 1, 0) à série, obtém-se AIC = 433,3; ao acrescentar o termo autorregressivo sazonal, formando o SARIMA(1, 1, 0)(1, 0, 0) $_{12}$, o AIC cai para 305,4, uma redução de 128 pontos. Como mostra a Tabela 2, todos os modelos sem componente sazonal permanecem com AIC acima de 412, enquanto os modelos com o termo sazonal ficam em torno de 305. A magnitude dessa diferença confirma que o ciclo anual é estrutura real e relevante da série, que o ARIMA não-sazonal não captura e o SARIMA incorpora.

5.2 Seleção e diagnóstico

A identificação das ordens seguiu a metodologia de Box e Jenkins (Morettin; Toloi, 2006): a FACP da série diferenciada sugere um termo autorregressivo ($p = 1$), a FAC não indica estrutura de médias móveis relevante ($q = 0$), e o decaimento no *lag* sazonal aponta um

componente autorregressivo sazonal ($P = 1$). Para confirmar, comparou-se uma grade de candidatos pelos critérios de informação de Akaike (AIC), Bayesiano (BIC) e Akaike corrigido (AICc), este último preferível em amostras pequenas. A Tabela 2 reúne os modelos com a mesma ordem de diferenciação ($d = 1$, $D = 0$), condição necessária para que os critérios sejam comparáveis entre si.

Tabela 2: Seleção de modelos SARIMA candidatos ($d = 1$, $D = 0$, $s = 12$), ordenados por AICc.

Modelo $(p, d, q)(P, D, Q)$	AIC	BIC	AICc
(1, 1, 0)(1, 0, 0)	305,4	309,2	306,5
(1, 1, 1)(1, 0, 0)	306,8	311,9	308,7
(0, 1, 2)(0, 0, 0)	412,2	416,9	412,9
(2, 1, 0)(0, 0, 0)	423,0	427,8	423,7
(1, 1, 1)(0, 0, 0)	423,8	428,7	424,6
(0, 1, 1)(0, 0, 0)	424,8	428,0	425,2
(1, 1, 0)(0, 0, 0)	433,3	436,5	433,6
(0, 1, 0)(0, 0, 0)	436,6	438,2	436,7

O modelo SARIMA(1, 1, 0)(1, 0, 0)₁₂ apresenta o menor AICc (306,5) e também o menor BIC, vencendo com folga os demais. A inclusão do termo de médias móveis (modelo (1, 1, 1)(1, 0, 0)) não melhora o ajuste e ainda penaliza o critério, confirmando $q = 0$. A diferença expressiva para os modelos sem componente sazonal (AICc acima de 412) demonstra que o termo sazonal (1, 0, 0)₁₂ é essencial: ignorá-lo deteriora substancialmente o ajuste.

Cabe esclarecer por que não se optou por um modelo puramente autorregressivo (AR) ou de médias móveis (MA) isolado. Em primeiro lugar, um AR ou MA sobre a série *em nível*, sem diferenciação, é inadequado porque a série é não-estacionária ($I(1)$, como mostrado na Seção 4): o teste ADF não rejeita a raiz unitária, de modo que a diferenciação $d = 1$ é necessária. De fato, um AR(1) em nível produz AIC de 448,6 e um MA(1) em nível, 577,7, ambos muito piores. Em segundo lugar, mesmo já aplicada a diferenciação, um modelo apenas com a parte regular, AR(1) como (1, 1, 0) ou MA(1) como (0, 1, 1), atinge AIC em torno de 433 e 425, pois deixa o ciclo anual sem tratamento. Em outras palavras, nem o AR nem o MA sozinhos dão conta da estrutura da série: é a combinação da diferenciação com o termo autorregressivo sazonal que produz o salto de qualidade observado.

Uma observação sobre a diferenciação sazonal vale aqui. Alguns modelos com diferenciação sazonal ($D = 1$) chegam a apresentar um AIC bem menor, mas esse número pode enganar: como o período é $s = 12$ e a série tem apenas $n = 40$ observações, diferenciar sazonalmente faz perder os doze primeiros pontos, e o critério passa a ser calculado sobre uma série bem mais curta, o que o reduz de forma artificial. Além disso, com tão poucos anos completos de dados, estimar uma componente sazonal diferenciada fica instável. Por isso preferi restringir a busca a modelos com $D = 0$, em linha com a recomendação de parcimônia de Morettin e Toloi (2006) para amostras pequenas. Vale destacar que isso não compromete o uso do AIC na seleção: todos os candidatos da Tabela 2 compartilham a mesma ordem de diferenciação ($d = 1$, $D = 0$) e são, portanto, calculados sobre a mesma quantidade de observações, de modo que a comparação entre eles é legítima. A ressalva acima diz respeito apenas à comparação entre modelos com $D = 0$ e $D = 1$, que

envolveria amostras de tamanhos diferentes.

Estimação dos parâmetros. Fixada a ordem $(1, 1, 0)(1, 0, 0)_{12}$, os coeficientes ϕ_1 (autorregressivo regular) e Φ_1 (autorregressivo sazonal) foram estimados por máxima verossimilhança (Morettin; Toloi, 2006). Sob a hipótese de ruído gaussiano, a função de verossimilhança da série diferenciada é construída a partir da densidade conjunta das observações, e os estimadores são os valores de ϕ_1 e Φ_1 que a maximizam. Na prática, a maximização é feita numericamente: o modelo é escrito em sua representação em espaço de estados, a verossimilhança é avaliada recursivamente pelo filtro de Kalman, e um otimizador busca o máximo. As estimativas obtidas foram $\hat{\phi}_1 = 0,59$ e $\hat{\Phi}_1 = 0,18$, ambos positivos, indicando persistência tanto de mês a mês quanto entre o mesmo mês de anos consecutivos. A variância do ruído estimada é $\hat{\sigma}_a^2 \approx 2.177$ (desvio-padrão de cerca de R\$47/ton).

A Figura 4 apresenta o ajuste e o diagnóstico dos resíduos do modelo escolhido. O teste de Ljung–Box no *lag* 12 não rejeita a ausência de autocorrelação ($p = 0,999$), indicando resíduos compatíveis com ruído branco. A normalidade é rejeitada (Shapiro–Wilk $p < 0,001$), comportamento esperado em preços de *commodities* sujeitos a choques, como se vê no histograma e no QQ-plot, influenciados pela queda de agosto de 2025, tratada adiante pela análise de intervenção. As métricas de ajuste dentro da amostra são $MAE = \text{R\$}76/\text{ton}$, $RMSE = \text{R\$}177/\text{ton}$ e $MAPE = 8,8\%$.




Figura 4: Ajuste do SARIMA e diagnóstico dos resíduos (QQ-plot, FAC e histograma).

6 Análise de Intervenção

A inspeção da série revela uma queda abrupta e persistente de patamar em meados de 2025: o preço, que vinha em torno de R\$1.185, recua para a faixa de R\$900 e ali permanece. Esse é exatamente o tipo de fenômeno que a análise de intervenção (Morettin; Toloi, 2006, cap. 12) trata: um evento externo que altera o nível da série num instante conhecido. Na formulação geral do capítulo 12, a série é modelada como

$$Z_t = \frac{\omega(B)}{\delta(B)} \xi_t^{(T)} + N_t,$$

em que N_t é o modelo SARIMA (o ruído), $\xi_t^{(T)}$ é a variável de intervenção acionada no instante T , e a razão $v(B) = \omega(B)/\delta(B)$ é a função de transferência que governa a dinâmica do efeito. Os polinômios $\omega(B)$ e $\delta(B)$ controlam, respectivamente, a magnitude e a persistência da resposta: quando $\delta(B) = 1$, o efeito é direto e o modelo se reduz a $Z_t = \omega_0 \xi_t^{(T)} + N_t$ (resposta abrupta); quando $\delta(B) = 1 - \delta_1 B$ com $0 < \delta_1 < 1$, o efeito se acumula gradualmente até estabilizar. A escolha da variável $\xi_t^{(T)}$ entre *degrau* ($S_t^{(T)} = 0$ para $t < T$ e 1 para $t \geq T$) e *pulso* ($P_t^{(T)} = 1$ apenas em $t = T$) determina se o efeito é permanente ou temporário. A identificação da forma correta de $v(B)$ é, portanto, parte central da análise.

Para identificar o instante T sem arbitrariedade, ajustou-se o modelo com uma variável de *degrau* para cada data candidata e selecionou-se aquela de menor AIC, procedimento na linha de Box e Tiao (Morettin; Toloi, 2006). O mês ótimo é agosto de 2025, quando o preço caiu R\$291/ton em relação ao mês anterior, a maior variação de toda a série. A Tabela 3 mostra os critérios de informação para as principais datas candidatas: agosto de 2025 destaca-se isoladamente, com AIC, BIC e AICc muito abaixo de todas as demais, que ficam próximas do modelo sem intervenção.

Tabela 3: Seleção da data de intervenção (degrau): critérios de informação por mês candidato, em ordem crescente de AIC.

Data do degrau	AIC	BIC	AICc	Efeito (R\$/ton)
Ago/2025	281,6	286,6	282,7	-291
Set/2025	305,3	310,3	306,4	+115
Jul/2025	305,8	310,8	306,9	+123
Jan/2025	305,9	311,0	307,1	+92
Nov/2024	306,1	311,1	307,3	+86
Mai/2025	306,2	311,2	307,3	+81
SARIMA sem intervenção: AIC = 305,4				

É importante distinguir o pico de maio/2025 (R\$1.269, o valor mais alto da série) da intervenção de agosto. O pico é apenas o topo de uma subida gradual iniciada no começo de 2025, movimento que o próprio SARIMA já captura como tendência, e portanto não constitui um evento: colocar a intervenção em maio resulta em AIC de 306,2, praticamente idêntico ao modelo sem intervenção (305,4), ou seja, não traz ganho algum. A intervenção verdadeira é a queda abrupta e permanente de julho (R\$1.185) para agosto (R\$894), quando a série muda de patamar e nele permanece. Em análise de intervenção, o que importa não é onde a série atinge seu valor mais alto, mas onde seu comportamento se altera de forma abrupta e duradoura. A seleção por AIC reflete exatamente essa distinção: apenas agosto reduz o critério de informação de forma expressiva (de 305,4 para 281,6), confirmando que o evento estrutural está na queda de agosto, não no pico de maio.

Comparando as duas formas canônicas de intervenção na mesma data, o *degrau* (efeito permanente; AIC = 281,6) supera o *pulso* (efeito temporário; AIC = 292,5), confirmando que se trata de uma mudança de patamar e não de um choque pontual, coerente com o que se observa no gráfico: o preço cai e permanece no novo nível.

Resta caracterizar a *forma* dessa resposta. A função de transferência $v(B)$ da intervenção pode produzir um efeito abrupto (que se manifesta integralmente no instante T) ou gradual (que cresce ao longo dos meses seguintes até estabilizar). A Tabela 4 compara

as formas por AIC, variando o parâmetro de persistência δ_1 nas variantes graduais.

Tabela 4: Forma da resposta da intervenção: critério de informação por tipo de efeito.

Forma da resposta	δ_1	AIC
Abrupta (degrau)	—	281,6
Gradual	0,3	285,6
Gradual	0,5	290,7
Gradual	0,7	296,2

A resposta abrupta apresenta o menor AIC, e o ajuste piora monotonicamente à medida que se aumenta δ_1 (resposta mais gradual). Isso indica que a queda se deu de uma só vez, sem transição suave. Em síntese, a intervenção é do tipo degrau abrupto: permanente e imediata. Este tipo de análise tem tradição na economia agrícola brasileira: Morettin e Toloi (2006) discutem aplicações da análise de intervenção a séries de produção e preço de café e de produtividade de leite em São Paulo, com mudanças de patamar associadas a fatores climáticos e de política agrícola, situação análoga à que se observa aqui no mercado do caroço de algodão.

Vale notar que o teste t elementar de comparação de médias antes e depois da intervenção (Morettin; Toloi, 2006, seção 12.4), que confronta $\bar{X}_1$ e $\bar{X}_2$ sob a hipótese $H_0 : \delta = \delta_0$, não rejeita a igualdade de médias ($p \approx 0,27$) nesta série. A razão é instrutiva: esse teste pressupõe que cada bloco seja aproximadamente estacionário em torno de sua média, o que não ocorre aqui, pois o bloco anterior contém o vale de 2024 e o pico de 2025, inflando a variância combinada e mascarando a quebra. É precisamente por isso que o modelo de intervenção completo, que controla tendência e sazonalidade via SARIMA, detecta a mudança de patamar que o teste t simples não captura.

O modelo final é o SARIMA(1, 1, 0)(1, 0, 0)₁₂ acrescido do degrau em ago/2025. A inclusão da intervenção reduz o AIC de 305,4 (modelo puro) para **281,6**, uma melhora de 23,8 pontos, e o efeito estimado do degrau é de R\$291/ton de queda permanente.

Explicitando, o modelo completo escreve-se, em termos do operador de defasagem B , como

$$\underbrace{(1 - \phi_1 B)}_{\text{AR}(1)} \underbrace{(1 - \Phi_1 B^{12})}_{\text{AR sazonal}} \underbrace{(1 - B)}_{\text{diferença}} (Z_t - \omega_0 S_t^{(T)}) = a_t,$$

onde Z_t é o preço, $S_t^{(T)}$ é o degrau acionado em agosto de 2025, a_t é o ruído branco e T marca o instante da intervenção. Substituindo as estimativas ($\phi_1 = 0,59$, $\Phi_1 = 0,18$, $\omega_0 = -291$ e $\sigma_a \approx 47$), obtém-se a forma estimada

$$(1 - 0,59 B)(1 - 0,18 B^{12})(1 - B)(Z_t + 291 S_t^{(T)}) = a_t.$$

A primeira diferença $(1 - B)$ remove a tendência estocástica; o fator $(1 - \phi_1 B)$ captura a dependência de curto prazo entre meses consecutivos; o fator sazonal $(1 - \Phi_1 B^{12})$ relaciona cada mês ao mesmo mês do ano anterior; e o termo $\omega_0 S_t^{(T)}$ desloca o nível da série em R\$291/ton a partir de agosto de 2025. A Figura 5 compara os ajustes: o modelo com intervenção acompanha melhor a transição de patamar de meados de 2025.




Figura 5: Ajuste do SARIMA puro *versus* SARIMA com intervenção em degrau (ago/2025).

Uma ressalva metodológica honesta: embora o AIC caia substancialmente, o coeficiente do degrau isolado não é fortemente significativo ($p \approx 0,30$), pois compartilha com o termo autorregressivo sazonal a explicação da mesma queda. Além disso, a análise de intervenção pressupõe o conhecimento da *causa* do evento; aqui, a data foi identificada estatisticamente, mas a atribuição a um fator econômico específico (por exemplo, uma supersafra ou queda do preço internacional da pluma) exigiria investigação adicional. Ainda assim, o exercício demonstra que a ferramenta do capítulo 12 endereça diretamente a quebra de patamar que, como se verá na Seção 7, limita a previsão do modelo sem intervenção.

Uma interpretação pela estrutura de safras. Há uma explicação concreta para a queda de patamar de agosto de 2025, ligada à forma como a série foi construída (Seção 2). Até julho de 2025, cada mês agrega *duas* safras simultaneamente: a 23/24, de preços elevados (em torno de R\$1.500/ton no fim de seu ciclo), e a 24/25, bem mais barata (em torno de R\$870/ton). A média mensal reflete as duas. A partir de setembro de 2025, encerrada a sobreposição, resta apenas a safra 24/25, e a série passa a refletir somente o seu nível, mais baixo. A quebra detectada pela análise de intervenção coincide, portanto, com o fim da sobreposição de safras: o degrau de R\$291/ton capta em grande parte a saída da safra cara (23/24) e a permanência da safra barata (24/25).

Essa leitura é corroborada quando se examina o preço de cada safra separadamente, como ilustra a Figura 6. Enquanto as duas safras coexistiram, a 23/24 foi negociada muito acima da 24/25, com uma diferença que chegou ao pico de R\$748/ton em maio de 2025 e permaneceu em torno de R\$274/ton na média dos vinte e um meses de sobreposição. Nesse período, a média mensal era sustentada para cima pela safra mais cara. Ao encerrar-se a 23/24 em agosto, a série passou a refletir apenas a 24/25, mais barata, e é essa transição que produz a mudança de patamar. A queda de agosto não é, assim, um choque puramente exógeno, mas em boa medida um reflexo da diferença de nível entre as safras combinada com o fim da sobreposição, o que torna o evento economicamente interpretável.




Figura 6: Preço por safra. À esquerda, as observações de cada safra e a média mensal (a série efetivamente analisada); à direita, a diferença de preço entre as safras nos meses de sobreposição, que atinge o pico em maio de 2025, às vésperas da quebra.

Diagnóstico do modelo com intervenção

Antes de prosseguir, verifica-se que o modelo final, com a intervenção incluída, permanece estatisticamente válido. A Tabela 5 compara os testes de diagnóstico aplicados aos resíduos do SARIMA puro e do SARIMA com intervenção. Em ambos, os resíduos não apresentam autocorrelação (Ljung-Box) nem heterocedasticidade condicional, avaliada pelo teste de multiplicadores de Lagrange para efeitos ARCH (Morettin; Toloi, 2006, cap. 14), confirmando que a estrutura temporal foi bem capturada e que não há volatilidade remanescente a justificar um modelo do tipo GARCH.

Tabela 5: Diagnóstico dos resíduos: p -valores dos testes de hipótese.

Teste (hipótese nula)	SARIMA puro	SARIMA + intervenção
Ljung-Box (sem autocorrelação)	0,860	0,673
ARCH-LM (homocedasticidade)	0,999	0,801
Shapiro-Wilk (normalidade)	0,001	0,122
Jarque-Bera (normalidade)	0,000	0,518

O resultado mais notável está na normalidade dos resíduos. No SARIMA puro, a hipótese de normalidade é *rejeitada* (Shapiro-Wilk $p = 0,001$; Jarque-Bera $p < 0,001$), porque a queda abrupta de agosto de 2025 figura como um resíduo extremo, uma observação muito distante das demais que distorce a distribuição. Ao modelar essa queda explicitamente com o degrau, ela deixa de ser um resíduo anômalo, e a hipótese de normalidade passa a *não ser rejeitada* (Shapiro-Wilk $p = 0,122$; Jarque-Bera $p = 0,518$). A Figura 7 comprova graficamente os dois aspectos do diagnóstico. Nos QQ-plots (coluna esquerda), o modelo puro (painel a) exibe o ponto inferior esquerdo afastando-se bruscamente da reta de referência, ao passo que no modelo com intervenção (painel c) os pontos alinham-se sobre a reta, confirmando a melhora na normalidade. Os gráficos de resíduos ao longo do tempo (coluna direita) mostram a mesma história sob a ótica da variância: no modelo puro (painel b), a queda de agosto aparece como um resíduo extremo que escapa da banda de ± 2 desvios, enquanto no modelo com intervenção (painel d) todos os resíduos permanecem dentro da banda, oscilando aleatoriamente em torno de zero. Em ambos

os modelos o teste ARCH-LM não rejeita a homocedasticidade ($p = 0,999$ e $p = 0,801$), de modo que não há volatilidade agrupada a justificar um modelo do tipo GARCH. A intervenção, portanto, não apenas reduz o AIC, mas também corrige a não-normalidade ao absorver o resíduo extremo, evidência adicional de que a quebra de patamar era a principal anomalia da série.




Figura 7: Diagnóstico dos resíduos. Coluna esquerda: QQ-plots de normalidade. Coluna direita: resíduos ao longo do tempo com banda de ± 2 desvios. Linha superior, SARIMA puro, com o resíduo extremo da queda de agosto; linha inferior, SARIMA com intervenção, com resíduos aproximadamente normais e dentro da banda.

7 Exercício de Previsão: 30 Observações de Treino, 10 de Teste

Para colocar o modelo à prova, fizemos um teste simples: estimamos o SARIMA com as 30 primeiras observações (jan/2023–jun/2025) e previram-se as 10 seguintes (jul/2025–abr/2026). A Tabela 6 apresenta, para cada mês, o valor observado, o previsto e o resíduo de previsão (observado menos previsto), além do erro percentual.

Tabela 6: Previsão fora da amostra: treino com 30 obs., previsão de 10. Resíduo = observado – previsto.

Mês	Observado	Previsto	Resíduo	Erro (%)
Jul/2025	1185	1158	+27	+2,3
Ago/2025	894	1141	−246	−27,5
Set/2025	907	1137	−230	−25,4
Out/2025	929	1140	−211	−22,7
Nov/2025	910	1167	−257	−28,2
Dez/2025	898	1189	−291	−32,5
Jan/2026	908	1220	−312	−34,3
Fev/2026	874	1226	−353	−40,4
Mar/2026	884	1253	−369	−41,7
Abr/2026	889	1282	−393	−44,2
MAE = R\$269/ton		RMSE = R\$287/ton	MAPE	29,9%

Os resíduos de previsão contam uma história interessante. O primeiro mês (jul/2025) é previsto com erro pequeno (+2,3%), mas a partir de agosto o resíduo torna-se sistematicamente negativo e crescente em módulo: o modelo superestima o preço. A explicação é que o período de treino termina justamente no pico histórico (mai/2025, R\$1.269), e o SARIMA, treinado apenas com esse regime de alta, projeta a manutenção do patamar elevado. Acontece que o preço real recuou de forma abrupta para a faixa de R\$900 em agosto. Como o modelo foi estimado sem a variável de intervenção, ele simplesmente não tem como prever essa quebra de patamar: o evento ocorre depois do fim do treino, em território que o modelo nunca viu. É por isso que as previsões ficam ruins a partir de agosto, e não por uma falha de especificação, mas porque nenhum modelo de coeficientes fixos preveria uma mudança de regime que ainda não ocorreu. A Figura 8 ilustra o exercício: nove das dez observações ainda permanecem dentro do intervalo de confiança de 95%, graças ao alargamento natural da incerteza com o horizonte, mas a previsão pontual afasta-se de forma sistemática do observado.

Esse alargamento dos intervalos com o horizonte não é acidental, mas uma propriedade teórica da previsão em modelos ARIMA (Morettin; Toloi, 2006). A previsão de origem t e horizonte h , denotada $\hat{Z}_t(h)$, é a esperança condicional que minimiza o erro quadrático médio. Escrevendo o modelo na forma de médias móveis infinita $Z_t = \sum_{j \geq 0} \psi_j a_{t-j}$, o erro de previsão de horizonte h acumula os choques futuros, $e_t(h) = \sum_{j=0}^{h-1} \psi_j a_{t+h-j}$, e sua variância é

$$\text{Var}[e_t(h)] = \sigma_a^2 \sum_{j=0}^{h-1} \psi_j^2,$$

que cresce monotonicamente com h . Por isso o intervalo de previsão $[\hat{Z}_t(h) \pm z_{\alpha/2} \sqrt{\text{Var}[e_t(h)]}]$ se alarga à medida que se prevê mais para frente: prever doze meses adiante é intrinsecamente mais incerto do que prever o mês seguinte. É esse alargamento que mantém nove das dez observações dentro da banda de 95%, ainda que a previsão pontual erre de forma sistemática.

Vale esclarecer que a intervenção identificada na Seção 6 não corrige a previsão deste exercício, pois a quebra ocorre em agosto de 2025, depois do encerramento do período de treino (junho de 2025). Um modelo treinado apenas com os dados até junho não tem como antecipar um evento que ainda não ocorreu; o benefício da intervenção manifesta-se

no ajuste da série completa e em previsões *posteriores* ao evento, quando o novo patamar já é conhecido. O exercício reflete, assim, a situação realista de prever o futuro sem conhecê-lo, e é justamente essa limitação que motiva a análise de intervenção.




Figura 8: Previsão fora da amostra com treino de 30 e horizonte de 10 observações.

8 Modelos Complementares

8.1 Modelo híbrido SARIMA $\rightarrow$ BTVC

Como extensão do objeto teórico do Projeto 1, considerou-se um modelo *híbrido* que acopla o SARIMA a um modelo bayesiano de coeficientes variáveis no tempo (BTVC). A ideia é usar a previsão do SARIMA como um regressor cujo peso varia ao longo do tempo: o componente bayesiano aprende, via MCMC, quanta confiança depositar na previsão clássica em cada instante. Formalmente,

$$y_t = \mu_t + \beta_t \hat{y}_t^{\text{SARIMA}} + s_t + \varepsilon_t,$$

em que μ_t é um nível local, s_t uma sazonalidade adaptativa, $\hat{y}_t^{\text{SARIMA}}$ a previsão do SARIMA e β_t o peso dinâmico (com β_t seguindo um passeio aleatório). A motivação é a limitação observada na Seção 7: um peso que se ajusta poderia reduzir a dependência do SARIMA quando este passa a errar. Vale notar que o componente SARIMA aqui empregado é o modelo *sem* intervenção, pela mesma razão do exercício de previsão: o híbrido é treinado nas 30 primeiras observações (até junho de 2025) e a quebra ocorre em agosto, fora desse período, de modo que não haveria como incorporar o degrau no treino. O híbrido busca, em vez disso, adaptar-se à mudança por meio do peso dinâmico β_t .

A Figura 9 mostra o ajuste e a trajetória estimada de β_t . O peso médio do SARIMA é baixo ($\bar{\beta} \approx 0,16$), indicando que o componente bayesiano se apoia sobretudo no próprio nível adaptativo. Para uma comparação justa com o SARIMA, repetiu-se o exercício de previsão da Seção 7: treino com as 30 primeiras observações e previsão das 10 seguintes. A Tabela 7 apresenta os resultados.

Tabela 7: Previsão fora da amostra do híbrido: treino com 30 obs., previsão de 10. Resíduo = observado – previsto.

Mês	Observado	Previsto	Resíduo	Erro (%)
Jul/2025	1185	1091	+94	+8,0
Ago/2025	894	1033	−139	−15,5
Set/2025	907	1021	−114	−12,5
Out/2025	929	1049	−120	−12,9
Nov/2025	910	1098	−188	−20,6
Dez/2025	898	1136	−238	−26,5
Jan/2026	908	1163	−255	−28,0
Fev/2026	874	1182	−309	−35,3
Mar/2026	884	1217	−332	−37,6
Abr/2026	889	1248	−359	−40,4
MAE = R\$215/ton		RMSE = R\$234/ton	MAPE	23,7%

Comparando com a Tabela 6, o híbrido obteve erro um pouco menor que o SARIMA puro no mesmo período (MAE de R\$215 contra R\$269; MAPE de 23,7% contra 29,9%). O componente de nível adaptativo reagiu de forma ligeiramente mais rápida à queda de patamar, reduzindo o viés de superestimação. Ainda assim, como ambos os modelos foram treinados no período de preços elevados, nenhum dos dois antecipou plenamente a reversão, e os resíduos permanecem expressivos.

Custo versus benefício. A melhora obtida pelo híbrido é modesta e não compensa, na prática, o aumento de complexidade. Enquanto o SARIMA é estimado por máxima verossimilhança em fração de segundo, o híbrido requer inferência por simulação estocástica (MCMC), com tempo de ajuste de ordens de magnitude superior, além de um número muito maior de parâmetros (níveis, pesos e coeficientes sazonais variáveis no tempo). Para a série em questão, esse custo adicional não se justifica: o ganho preditivo é pequeno e o modelo mais simples (SARIMA) é preferível pelo princípio da parcimônia (Morettin; Toloi, 2006). O híbrido permanece relevante apenas como referência conceitual e como opção para cenários de instabilidade mais acentuada, em que a adaptabilidade dos coeficientes traria benefício maior.




Figura 9: Previsão fora da amostra do modelo híbrido: treino com 30 observações e horizonte de 10, com intervalo de credibilidade de 95%.

9 Discussão Crítica e Conclusão

Recapitulando o percurso: a série é $I(1)$, com tendência predominante e sazonalidade anual moderada. O modelo SARIMA(1, 1, 0)(1, 0, 0)₁₂ ajusta-se bem dentro da amostra, com resíduos compatíveis com ruído branco, e é adequado para previsão de curto prazo em condições regulares.

O exercício de previsão 30/10 (Seção 7) expõe a principal limitação do modelo: treinado num período de preços elevados, não antecipou a queda abrupta subsequente, acumulando resíduos de previsão de até R\$393/ton (MAPE de 30%). Essa fragilidade diante de mudanças de patamar é inerente a modelos de coeficientes constantes e motiva o complemento híbrido SARIMA $\rightarrow$ BTVC (que reduziu modestamente o erro de previsão, de MAPE 29,9% para 23,7%, graças ao nível adaptativo, mas sem reverter plenamente o viés). A própria quebra de patamar foi interpretada pela estrutura de safras, mostrando que a diferença de preço entre as safras sobrepostas, e o fim dessa sobreposição, explicam em boa parte a mudança de nível.

Limitações e melhorias. (i) O tamanho amostral ($n = 40$) é modesto para a estimação sazonal. (ii) A análise de intervenção (Seção 6) tratou a quebra de patamar de ago/2025 e reduziu o AIC de forma expressiva; um próximo passo seria identificar a *causa* econômica do evento para fundamentar a intervenção além do critério estatístico. (iii) Variáveis exógenas, como câmbio e preço da pluma, poderiam ser incorporadas via modelo ARMAX.

Referências

- MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais*. 2. ed. São Paulo: Egard Blucher, 2006. ISBN 978-85-212-0389-6.
- SHUMWAY, R. H.; STOFFER, D. S. *Time Series Analysis and Its Applications*. 4. ed. Nova Iorque: Springer, 2017. ISBN 978-3319524511.